

Moussa DIALLO

Data Analyst / Data Scientist, Statistiques & Visualisation

Tél : 06 65 78 47 63 · Email : diallomoussa052001@gmail.com · Toulouse / Île-de-France, mobile en France
https://github.com/dialloalassane052001-ui · https://www.linkedin.com/in/moussa-diallo-b203473a2/

PROFIL

Titulaire d'un Master 2 Mathématiques Appliquées (MApI3, Université de Toulouse), attestation de réussite obtenue, diplôme officiel en décembre 2026. Data Analyst junior avec une forte orientation statistiques, exploration de données et visualisation. Mes stages en laboratoire m'ont appris à transformer des données hétérogènes et volumineuses en analyses fiables, tableaux de synthèse et recommandations claires.

Ce que je recherche : un poste de Data Analyst, Business Analyst ou Data Scientist en CDI ou CDD, disponible à partir d'octobre 2026, partout en France. Je souhaite accompagner les équipes métier et de recherche dans la prise de décision à partir de données complexes.

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire — Analyse de données & IA multimodale | Matériaux

Laboratoire L2MGC, CY Cergy Paris Université · avril 2026 – juillet 2026 · Neuville-sur-Oise

- Collecte et structuration de données issues de 388 articles scientifiques (Python, API CrossRef, web scraping).
- Nettoyage, fiabilisation et analyse exploratoire de 2 297 formulations et 483 images MEB/BSE.
- Association automatique de 141 images à leur formulation (caption-matching).
- Entraînement et benchmark de 6 modèles de Machine Learning (XGBoost, Random Forest, MLP, ResNet18, fusion multimodale) avec validation croisée.
- Meilleur modèle** : XGBoost avec $R^2 = 0,76$ et $MAE < 10$ MPa sur la prédiction de la résistance en compression.
- Interprétabilité des modèles** : t-SNE et Grad-CAM.

Environnement : Python (pandas, NumPy, scikit-learn, OpenCV), PyTorch, XGBoost, Git.

Stagiaire R&D — Interprétabilité et visualisation de réseaux de neurones

IRIT (Institut de Recherche en Informatique de Toulouse) · mai 2025 – août 2025 · Toulouse

- Développement d'outils pour visualiser les activations des neurones et les cartes d'attention (ce qui déclenche une décision du réseau).
- Analyse de l'importance des variables et des zones de l'image qui influencent la prédiction.
- Création de tableaux de bord interactifs pour permettre aux chercheurs d'explorer visuellement le comportement des modèles.
- Restitution et documentation des résultats pour l'équipe de recherche.

Environnement : Python, PyTorch, NumPy, Matplotlib, Jupyter, Git.

PROJETS

- Agent IA de candidature** : analyse sémantique d'offres et de CV, scoring de correspondance, génération automatique de recommandations via LLM.
- Prévision de séries temporelles** : étude exploratoire (décomposition, tendances, saisonnalité) et modélisation par RNN, LSTM, GRU.
- Demosaïcage d'images couleur** : inversion du filtre de Bayer par optimisation variationnelle (variation totale), avec étude de convergence.

FORMATION

Master 2 Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

Université de Toulouse, Paul Sabatier · septembre 2025 – août 2026 · Diplômé (attestation de réussite ; diplôme officiel décembre 2026)

- Mathématiques du machine learning, réseaux de neurones profonds, optimisation, calcul scientifique, traitement du signal et de l'image, statistiques avancées, recherche opérationnelle, plan d'expérience et analyse d'incertitude, Big Data.

Master 1 Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MAPI3)

Université de Toulouse, Paul Sabatier · septembre 2024 – août 2025

- EDP et méthodes numériques, optimisation, probabilités, statistiques, simulation aléatoire, image, signal, algorithmique et calcul scientifique.

Licence Mathématiques Appliquées (MApI3)

Université de Toulouse, Paul Sabatier · septembre 2021 – mai 2023

- L3 MApI3 : Licence Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation.
- L1–L2 CUPGE : Cycle universitaire préparatoire aux grandes écoles – Sciences pour l'Ingénieur (Maths, Physique, Informatique, Chimie).

COMPÉTENCES

Analyse & SQL : nettoyage et qualité de données, détection d'anomalies, structuration data-centric, analyse exploratoire, web scraping (API CrossRef).

Statistiques : inférence statistique, tests d'hypothèses, corrélations, Monte-Carlo, bootstrap, quantification d'incertitude, plans d'expériences.

Visualisation & restitution : Matplotlib, tableaux de synthèse, dashboards interactifs, storytelling data, présentations aux équipes de recherche.

Machine Learning & IA : scikit-learn, XGBoost, Random Forest, MLP, PyTorch, CNN, ResNet, RNN/LSTM/GRU, validation croisée, XAI (Grad-CAM, t-SNE).

Langages & outils : Python (pandas, NumPy, SciPy, Matplotlib, OpenCV), SQL, MATLAB, Git/GitHub, Jupyter, LaTeX.

Signal & image : filtrage, segmentation multi-Otsu, matrices GLCM, transformées (Fourier, ondelettes), métriques PSNR/SSIM.

LANGUES

Français : courant · Anglais : B2 (documentation technique, rédaction scientifique).