

MOUSSA DIALLO

Data Analyst Junior | Data Scientist

Toulouse / Île-de-France (mobile en France) | 06 65 78 47 63 | diallomoussa052001@gmail.com
Linkedin : [Moussa Diallo](#) | Github : [github.com](#) | Portfolio : [Moussa Diallo](#)

PROFIL

Data Analyst junior diplômé d'un Master 2 Mathématiques Appliquées (Université de Toulouse III Paul Sabatier, 2026). Deux stages en laboratoire de recherche : analyse exploratoire, analyse statistique et visualisation de données complexes (tabulaires et images), interprétation des résultats et restitution aux équipes via des dashboards interactifs. Recherche un poste de Data Analyst / Data Scientist junior en CDI ou CDD. Disponible immédiatement.

FORMATION

Master 2 Mathématiques Appliquées (MApl3)2025 – 2026

Université de Toulouse III Paul Sabatier · Attestation de réussite obtenue

Master 1 Mathématiques Appliquées (MApl3)2024 – 2025

Université de Toulouse III Paul Sabatier

Licence Mathématiques Appliquées (CUPGE puis L3)2021 – 2024

Université de Toulouse III Paul Sabatier

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire – Analyse de données & IA multimodale Avril 2026 – Juillet 2026

Laboratoire L2MGC, CY Cergy Paris Université

- **Analyse de données** : jeu de 2 297 formulations (43 variables) et 483 images analysé pour identifier les facteurs prédictifs de la résistance du béton ; 6 approches comparées (XGBoost, Random Forest, MLP, ResNet18, fusion) ; meilleur résultat : $R^2 = 0,76$ et $MAE < 10$ MPa.
- **Préparation des données** : analyse exploratoire et feature engineering (multi-Otsu, GLCM, caption-matching : 141 images associées automatiquement à leur formulation) sur 388 articles ; +86 % de données exploitables.
- **Restitution** : résultats interprétés par t-SNE et Grad-CAM et présentés aux chercheurs pour orienter leurs choix de modélisation.
- **Environnement** : Python (pandas, scikit-learn, OpenCV), PyTorch, XGBoost, Git.

Stagiaire R&D – Explicabilité de réseaux de neurones (XAI) Mai 2025 – Août 2025

Laboratoire IRIT, Université de Toulouse

- **Analyse de modèles** : décisions de CNN et ResNet analysées via Grad-CAM et importance des filtres pour repérer zones d'incertitude et biais potentiels.
- **Dashboards** : dashboards interactifs (Python, Matplotlib) transformant ces analyses en visualisations exploitables par les équipes de recherche.
- **Reproductibilité** : analyses et implémentations documentées sous Git. Environnement : Python, PyTorch, NumPy, Jupyter, Git.

COMPÉTENCES

Analyse & statistiques : Python, SQL (bases), pandas, NumPy, SciPy, statistiques inférentielles, analyse exploratoire, validation croisée, Monte-Carlo

Visualisation : Matplotlib, Seaborn, Plotly, dashboards interactifs, Streamlit

Machine Learning : scikit-learn, XGBoost, PyTorch, CNN / ResNet, XAI (Grad-CAM, t-SNE)

Données & outils : pipelines ETL, web scraping, API REST / JSON, Git / GitHub, Linux, Jupyter

PROJETS

- **Agent IA de candidature (projet personnel)** : analyse sémantique offre / CV et score de correspondance par LLM (API Gemini), génération de lettres de motivation ; application Streamlit déployée sur Streamlit Cloud.
- **Classification & explicabilité d'images (PyTorch, projet M2)** : classification binaire (MNIST, Muffin vs Chihuahua) par CNN / ResNet ; analyse comparative Grad-CAM selon la complexité des données.
- **Classification de paysages (PyTorch)** : 4 000 images, 7 classes ; comparaison from-scratch, data augmentation, transfer learning ; visualisation t-SNE.

LANGUES

Français : courant | **Anglais** : B2 (documentation technique, veille, rédaction)