



# MOUSSA DIALLO

## DATA SCIENTIST JUNIOR & DATA ANALYSIS & STATISTIQUES

Téléphone : 06 65 78 47 63 | Email : dialloumoussa052001@gmail.com

Localisation : Toulouse, mobile partout en France | Disponibilité : immédiate (CDI / CDD)

GitHub : [github.com/dialloalassane052001-ui](https://github.com/dialloalassane052001-ui) | LinkedIn : [linkedin.com/in/moussa-diallo-b203473a2](https://linkedin.com/in/moussa-diallo-b203473a2)

### PROFIL

**Master 2 Mathématiques Appliquées (MApI3, Université de Toulouse) validé**, diplôme officiel délivré en décembre 2026. **Data Scientist junior spécialisé en IA multimodale**, avec une forte orientation **Data Analysis** : SQL, statistiques inférentielles, visualisation et restitution de résultats. Mes deux stages en laboratoire m'ont appris à transformer des données hétérogènes et volumineuses en analyses fiables, tableaux de synthèse et recommandations claires pour les équipes de recherche. Je recherche un poste de **Data Analyst** en CDI ou CDD, partout en France.

**Réalisations clés** : analyse SQL et structuration de **2 297 formulations** (43 variables) et **388 images** • dashboards interactifs adoptés par les équipes de recherche (L2MGC) • segmentation d'images BSE et corrélations statistiques (porosité  $r = 0,52$ ).

### EXPÉRIENCE PROFESSIONNELLE

#### Data Scientist stagiaire, analyse de données scientifiques & restitution

2026 — présent

Laboratoire L2MGC, CY Cergy Paris Université

Cergy, France

- Analyse SQL** : nettoyage et structuration d'une base de **2 297 formulations** (43 variables) et **388 images** ; requêtes multi-critères et analyses exploratoires.
- Analyse statistique** : détection d'anomalies, gestion des valeurs manquantes et doublons ; mise en évidence de corrélations (porosité surfacique  $r = 0,52$ ).
- Extraction automatisée** : collecte de **388 articles** via API CrossRef et normalisation pour analyse.
- Analyse d'incertitude** : simulations **Monte-Carlo** et bootstrap pour quantifier la robustesse des analyses.
- Visualisation et restitution** : tableaux de synthèse et graphiques (Matplotlib) présentés aux chercheurs ; recommandations opérationnelles.
- Modélisation** : benchmark de **6 modèles** en validation croisée ; **XGBoost meilleur modèle avec  $R^2 = 0,76$** .

**Environnement** : SQL, Python (pandas, NumPy, SciPy, Matplotlib, scikit-learn), XGBoost, Git, LaTeX.

#### Stagiaire R&D, analyse et visualisation de données de modèles

2024

Laboratoire IRIT, Université de Toulouse

Toulouse, France

- Analyse de données de modèles** : extraction et traitement des sorties de CNN/ResNet pour identifier les patterns de classification.
- Dashboards interactifs** : conception de visualisations (Python, Matplotlib) pour explorer prédictions et explications, adoptés par les équipes de recherche.
- Implémentation reproductible en Python (PyTorch, NumPy) avec documentation technique.

**Environnement** : Python, PyTorch, NumPy, Matplotlib, Jupyter.

### PROJETS

#### Agent IA de candidature, scoring et analyse de correspondance

2026 — présent

**Analyse sémantique** d'offres d'emploi et de CV : scoring de correspondance, mise en évidence des écarts et génération automatique de recommandations via LLM.

#### Prévision de séries temporelles par Deep Learning

2025 — présent

Étude exploratoire et modélisation de séries temporelles (dont financières) : décomposition, tendances, saisonnalité, préparation pour modèles prédictifs (RNN, LSTM, GRU).

#### Reconstruction d'images et analyse statistique sous incertitude

2025 — présent

Reconstruction d'images couleur (capteur de Bayer) évaluée par PSNR / SSIM ; étude de robustesse par simulations de **Monte-Carlo** et bootstrap.

### FORMATION

#### Master Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

2024 — 2026

Université de Toulouse

Toulouse, France

- M2 MApI3 (2025 — 2026)** : Machine learning, réseaux de neurones profonds, big data, statistiques avancées, optimisation, traitement du signal et de l'image, recherche opérationnelle. *M2 validé (attestation de réussite ; diplôme officiel en décembre 2026)*.
- M1 MApI3 (2024 — 2025)** : Statistiques inférentielles, modélisation stochastique, méthodes numériques (EDP), Monte-Carlo, plans d'expériences, analyse d'incertitude.

#### Licence Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

2020 — 2023

Université de Toulouse

Toulouse, France

- L3 MApI3 (2022 — 2023)** : Mathématiques appliquées à l'ingénierie, l'industrie et l'innovation.
- L1 — L2 CUPGE (2020 — 2022)** : Cycle Universitaire Préparatoire aux Grandes Écoles — analyse réelle et complexe, topologie, algèbre linéaire et calcul matriciel, probabilités et statistiques, programmation scientifique (Python, MATLAB).

### COMPÉTENCES

**Analyse & SQL** : SQL (requêtes multi-tables, agrégations, jointures), conception de bases relationnelles, nettoyage et qualité de données, détection d'anomalies, structuration data-centric.

**Statistiques** : inférence statistique, tests d'hypothèses, corrélations, Monte-Carlo, bootstrap, quantification d'incertitude, plans d'expériences.

**Visualisation & restitution** : Matplotlib, tableaux de synthèse, dashboards interactifs, storytelling data, présentations aux équipes métier et de recherche.

**Langages et outils** : Python (pandas, NumPy, SciPy, Matplotlib), SQL, MATLAB, Git/GitHub, Jupyter, LaTeX.

**Machine Learning et IA** : scikit-learn, XGBoost, PyTorch, TensorFlow/Keras, CNN, ResNet, RNN/LSTM/GRU, SVM, forêts aléatoires, clustering (k-means, DBSCAN), régularisation (ridge, lasso), validation croisée, XAI (Grad-CAM, t-SNE).

**Signal et image** : filtrage, segmentation, transformées (Fourier, ondelettes), reconstruction, métriques PSNR / SSIM.

### LANGUES

**Français** : courant | **Anglais** : B2, documentation technique et rédaction scientifique.