

MOUSSA DIALLO

Data Engineer / Data Analyst , Pipelines de Données & Structuration, Mathématiques Appliquées

06 65 78 47 63 · diallomoussa052001@gmail.com · Toulouse / Île-de-France, mobile en France · [LinkedIn : Moussa Diallo](#) · [GitHub dialloalassane052001-ui](#)

PROFIL

Titulaire d'un Master 2 Mathématiques Appliquées (MApI3, Université de Toulouse), attestation de réussite obtenue, diplôme officiel en décembre 2026. Spécialisé dans la construction de pipelines de données de bout en bout : collecte automatisée (API, web scraping), nettoyage, structuration et industrialisation de jeux de données volumineux, jusqu'à la mise à disposition pour des modèles prédictifs. Deux expériences en laboratoire de recherche sur la conception de pipelines ETL, l'intégration de données hétérogènes (tabulaires, images) et le déploiement d'outils data (dashboards, API, applications).

Ce que je recherche : un poste de Data Engineer, Data Analyst ou Analytics Engineer en CDI ou CDD, disponible à partir d'octobre 2026, partout en France.

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire — IA multimodale pour la prédiction de propriétés de matériaux avril 2026 – juillet 2026

Laboratoire L2MGC, CY Cergy Paris Université

- Conception d'un **pipeline de collecte et structuration de données** multi-sources (tabulaires + images microscopiques MEB/BSE) pour la prédiction de la résistance mécanique du béton.
- **Data engineering** : collecte automatisée de 388 articles scientifiques (API CrossRef, web scraping) ; conception d'un pipeline ETL structurant 2 297 formulations (43 variables) et 483 images en base exploitable.
- **Feature engineering & nettoyage de données** : segmentation multi-Otsu, extraction de features (matrices GLCM), caption-matching automatisé, gain de +86 % de données exploitables.
- **Industrialisation & qualité des données** : benchmark de 6 modèles sur les données structurées, versionnement Git, requêtes SQL pour l'exploration et le contrôle qualité du jeu de données.
- **Restitution** : documentation du pipeline et présentation des résultats aux équipes de recherche.

Environnement : Python (pandas, SQL, scikit-learn, OpenCV), pipelines ETL, API REST/JSON, web scraping, Git.

Stagiaire R&D — Explicabilité de réseaux de neurones (XAI) mai 2025 – août 2025

Laboratoire IRIT, Université de Toulouse

- Conception de **dashboards interactifs** (Python, Matplotlib) pour visualiser et fiabiliser les sorties de modèles, adoptés en production par les équipes de recherche.
- **Structuration et versionnement** du code et des données d'expérimentation (Git), documentation technique.
- **Développement d'outils** d'explicabilité (Grad-CAM) intégrés à un pipeline reproductible.

Environnement : Python, PyTorch, NumPy, Matplotlib, Jupyter, Git , etc.

COMPÉTENCES

Data Engineering : SQL, pipelines ETL, web scraping (BeautifulSoup, Selenium), API REST/JSON, Git/GitHub, Linux, Docker (bases), FastAPI, Streamlit.

Data Analyse & Stats : pandas, NumPy, SciPy, statistiques inférentielles, Monte-Carlo, détection d'anomalies, Matplotlib/Seaborn/Plotly.

Machine Learning & IA : PyTorch, TensorFlow/Keras, scikit-learn, XGBoost/LightGBM, CNN, ResNet, RNN/LSTM/GRU, Transformers, NLP (LLM), Computer Vision, XAI (Grad-CAM, t-SNE).

Calcul scientifique : optimisation, traitement du signal/image, MATLAB, OpenCV.

Notions : Spark/PySpark, AWS (S3, EC2), GCP.

PROJETS

Agent IA de candidature (Python, LLM Gemini API) — **Pipeline complet de bout en bout** : ingestion et analyse sémantique offre/CV, scoring de correspondance, génération automatique de lettres ; application web Streamlit + CLI, traitement par lot, déployé sur Streamlit Cloud.

Pipeline de classification d'images — CNN, ResNet & Grad-CAM (PyTorch, projet d'équipe M2) — **structuration d'un jeu de données** (MNIST, Muffin vs. Chihuahua), classification par CNN/ResNet, analyse des décisions du modèle.

Pipeline de classification de paysages — Deep Learning & Transfer Learning (PyTorch) — **constitution et structuration d'un jeu de 4 000 images / 7 classes** ; comparaison from-scratch, data augmentation et transfer learning.

FORMATION

Master 2 Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3) — Université de Toulouse Paul Sabatier · 2025–2026 · Diplômé (attestation de réussite ; diplôme officiel décembre 2026)

Master 1 MApI3 — Université de Toulouse Paul Sabatier · 2024–2025

Licence Mathématiques Appliquées (MApI3, dont CUPGE) — Université de Toulouse Paul Sabatier · 2021–2023

LANGUES

Français : courant · Anglais : B2 (documentation technique, rédaction scientifique)