

MOUSSA DIALLO

Data Engineer Junior | ML Engineer

Pipelines de données & Machine Learning | Mathématiques Appliquées

Toulouse / Île-de-France (Mobile en France) • 06 65 78 47 63 • dialloumoussa052001@gmail.com

LinkedIn : [Moussa Diallo](#) • GitHub : [github.com](#) • Portfolio : [Moussa Diallo](#)

PROFIL

Data Engineer junior, diplômé d'un Master 2 en Mathématiques Appliquées de l'Université de Toulouse. Formé par deux stages en laboratoires de recherche (IRIT, L2MGC), je dispose d'une double compétence en conception de pipelines de données et en Machine Learning. Spécialisé dans la collecte automatisée, la structuration ETL et la mise à disposition de jeux de données complexes. Recherche un poste de Data Engineer / Analytics Engineer (CDI/CDD). Disponible immédiatement, mobile en France.

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire | Avril 2026 – Juillet 2026

Laboratoire L2MGC, CY Cergy Paris Université

Spécialisation : Ingénierie des données et architecture de pipelines pour l'IA multimodale

- **Pipelines & Ingestion** : Conçu et développé un pipeline de collecte automatisée (API CrossRef, web scraping) sur 388 articles scientifiques, puis structuré une base de 2 297 formulations (43 variables) et 483 images.
- **Feature Engineering** : Développé un pipeline (segmentation multi-Otsu, matrices GLCM, caption-matching : 141 images associées automatiquement à leur formulation) qui a augmenté de 86 % le volume de données exploitables.
- **Modélisation & Qualité** : Mis en place et comparé 6 architectures (XGBoost, Random Forest, MLP, ResNet18, fusion multimodale) sur les données produites : $R^2 = 0,76$, MAE < 10 MPa, avec contrôle qualité par interprétabilité (t-SNE, Grad-CAM).

Environnement technique : Python (pandas, scikit-learn, OpenCV), PyTorch, XGBoost, SQL, Git

Stagiaire R&D – Pipelines & Industrialisation (XAI) | Mai 2025 – Août 2025

Laboratoire IRIT, Université de Toulouse

- **Architecture du code** : Développé et versionné (Git) des modules Python/PyTorch/NumPy réutilisables pour automatiser le calcul d'explicabilité sur des réseaux CNN et ResNet.
- **Restitution Data** : Conçu des dashboards interactifs (Python, Matplotlib) connectés aux modules pour permettre aux équipes d'exploiter les résultats sans recoder les analyses.
- **Documentation** : Documenté l'ensemble du pipeline (code, dépendances, structure des données) pour faciliter sa reprise et sa maintenance.

Environnement technique : Python, PyTorch, NumPy, Matplotlib, Jupyter, Git

COMPÉTENCES

- **Data Engineering & Scraping** : Pipelines ETL, ingestion de données, SQL, web scraping (BeautifulSoup, Selenium), API REST/JSON, Streamlit
- **Outils & Architecture** : Git/GitHub, Linux (bases), Docker, FastAPI ; Notions : Spark/PySpark, AWS, GCP
- **Machine Learning & IA** : PyTorch, TensorFlow/Keras, scikit-learn, XGBoost, CNN, ResNet, LLM (API Gemini), Computer Vision, XAI (Grad-CAM, t-SNE)
- **Calcul scientifique & Stats** : Pandas, NumPy, SciPy, statistiques inférentielles, Monte-Carlo, optimisation, OpenCV, MATLAB

PROJETS

- **Agent IA de candidature (Python, LLM/Gemini API)** : Pipeline complet (ingestion offre/CV, scoring, génération de lettres) packagé en application Streamlit + CLI, avec traitement par lot, déployé sur Streamlit Cloud.
- **Classification et explicabilité d'images (PyTorch)** : Pipeline de classification binaire (MNIST, Muffin vs. Chihuahua) par CNN/ResNet, avec module d'analyse Grad-CAM des décisions selon la complexité des données.
- **Classification de paysages (Deep & Transfer Learning)** : Pipeline d'entraînement sur 4 000 images / 7 classes ; comparaison from-scratch vs. data augmentation vs. transfer learning ; visualisation t-SNE.

FORMATION

- **Master 2 Mathématiques Appliquées (MAPI3)** | Université de Toulouse Paul Sabatier (2025 – 2026) — *Diplôme obtenu (Attestation de réussite)*
- **Master 1 MAPI3** | Université de Toulouse Paul Sabatier (2024 – 2025)
- **Licence Mathématiques Appliquées & CUPGE** | Université de Toulouse Paul Sabatier (2021 – 2024)

LANGUES

- **Français** : Courant (langue de travail)
- **Anglais** : B2 (documentation technique, rédaction scientifique)