



Moussa DIALLO

Data Engineer / Data Analyst , Pipelines & Structuration de Données

Tél : 06 65 78 47 63 Email : diallomoussa052001@gmail.com
Toulouse / Île-de-France, mobile en France <https://github.com/dialloalassane052001-ui> <https://www.linkedin.com/in/moussa-diallo-b203473a2/>

PROFIL

Titulaire d'un Master 2 Mathématiques Appliquées (MApI3, Université de Toulouse), attestation de réussite obtenue, diplôme officiel en décembre 2026. Profil hybride Data Engineer / Data Analyst avec une forte expérience en **collecte automatisée de données**, **nettoyage et structuration** de jeux de données hétérogènes, et **fiabilisation de la qualité**. Mes stages en laboratoire m'ont appris à construire des pipelines robustes, de la source brute jusqu'à l'analyse exploitable.

Ce que je recherche : un poste de Data Engineer, Data Analyst ou Analytics Engineer en CDI ou CDD, disponible à partir d'octobre 2026, partout en France. Je souhaite concevoir et maintenir des pipelines de données fiables, structurer des bases exploitables et accompagner les équipes dans la valorisation des données.

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire — Collecte, structuration et qualité de données scientifiques

Laboratoire L2MGC, CY Cergy Paris Université · avril 2026 – juillet 2026 · Neuville-sur-Oise

- Pipeline de collecte automatisée** : extraction de 388 articles scientifiques via API CrossRef et web scraping, avec parsing et normalisation (Python, JSON).
- Structuration de données** : nettoyage, fiabilisation et analyse exploratoire de 2 297 formulations (43 variables) et 483 images MEB/BSE.
- Automatisation** : association automatique de 141 images à leur formulation (caption-matching).
- Qualité des données** : détection d'anomalies, gestion des valeurs manquantes et doublons, traçabilité des corrections.
- Exploitation analytique** : benchmark de 6 modèles de Machine Learning (XGBoost, Random Forest, MLP, ResNet18, fusion multimodale) avec validation croisée ; XGBoost meilleur : $R^2 = 0,76$, MAE < 10 MPa.
- Restitution** : interprétabilité des modèles (t-SNE, Grad-CAM) et présentation des résultats aux chercheurs.

Environnement : Python (pandas, NumPy, scikit-learn, OpenCV), API REST (CrossRef), web scraping, PyTorch, XGBoost, Git.

Stagiaire R&D — Analyse et visualisation de données de modèles

IRIT (Institut de Recherche en Informatique de Toulouse) · mai 2025 – août 2025 · Toulouse

- Extraction et traitement des sorties de modèles de vision (activations de neurones, cartes d'attention) pour analyse.
- Création de tableaux de bord interactifs pour l'exploration visuelle des données par les chercheurs.
- Documentation et versioning des scripts d'analyse (Python, PyTorch, NumPy).

Environnement : Python, PyTorch, NumPy, Matplotlib, Jupyter, Git.

PROJETS

- Agent IA de candidature** : pipeline complet d'analyse sémantique d'offres et de CV, scoring, intégration d'un LLM, déploiement web.
- Prévision de séries temporelles** : préparation et structuration des données, modélisation par RNN, LSTM, GRU sous PyTorch.
- Demosaïcage d'images couleur** : inversion du filtre de Bayer par optimisation variationnelle (variation totale), avec étude de convergence .

FORMATION

Master 2 Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation(MApI3)

Université de Toulouse, Paul Sabatier · septembre 2025 – août 2026 · Diplômé (attestation de réussite ; diplôme officiel décembre 2026)

- Mathématiques du machine learning, réseaux de neurones profonds, optimisation, calcul scientifique, traitement du signal et de l'image, statistiques avancées, recherche opérationnelle, Plan d'expérience et analyse d'incertitude, Big Data.

Master 1 Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation(MApI3)

Université de Toulouse, Paul Sabatier · septembre 2024 – août 2025

- EDP et méthodes numériques, optimisation, probabilités, statistiques, Simulation aléatoire, Image, signal, ALGORITHMIQUE et CALCUL Scientifique.

Licence Mathématiques Appliquées (MApI3)

Université de Toulouse, Paul Sabatier · septembre 2021 – mai 2023

- L3 MApI3 : Licence Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation.
- L1–L2 CUPGE : Cycle universitaire préparatoire aux grandes écoles - Sciences pour l'Ingénieur (Maths, Physiques, Informatiques et Chimies)

COMPÉTENCES

Data Engineering & Pipelines : collecte automatisée (API REST, web scraping BeautifulSoup/requests), parsing JSON, pipelines ETL, structuration et normalisation de données hétérogènes, automatisation de traitements (Python), gestion de la qualité des données (valeurs manquantes, doublons, anomalies).

Bases de données & SQL : SQL (requêtes multi-tables, agrégations, jointures), conception et structuration de bases relationnelles, modélisation de données, traçabilité.

Langages & outils : Python (pandas, NumPy, SciPy, Matplotlib, OpenCV), SQL, MATLAB, Git/GitHub, Jupyter, LaTeX, Linux (bases), Bash (bases).

Analyse & exploitation : analyse exploratoire, statistiques inférentielles, tests d'hypothèses, Monte-Carlo, bootstrap, quantification d'incertitude, datavisualisation (Matplotlib), dashboards interactifs.

Machine Learning (bonus) : scikit-learn, XGBoost, Random Forest, MLP, PyTorch, CNN, ResNet, RNN/LSTM/GRU, XAI (Grad-CAM, t-SNE), validation croisée.

LANGUES

Français : courant · Anglais : B2 (documentation technique, rédaction scientifique).