



MOUSSA DIALLO

DATA SCIENTIST JUNIOR & DATA ENGINEERING & PIPELINES

Téléphone : 06 65 78 47 63 | Email : diallomoussa052001@gmail.com

Localisation : Toulouse, mobile partout en France | Disponibilité : immédiate (CDI / CDD)

GitHub : github.com/dialloalassane052001-ui | LinkedIn : linkedin.com/in/moussa-diallo-b203473a2

PROFIL

Master 2 Mathématiques Appliquées (MApI3, Université de Toulouse) validé, diplôme officiel délivré en décembre 2026. **Data Scientist junior spécialisé en IA multimodale**, avec une forte orientation **Data Engineering** (pipelines ETL, structuration SQL, qualité et traçabilité des données). Mes deux stages en laboratoire m'ont permis de couvrir toute la chaîne, de la collecte automatisée à la mise à disposition de données fiables pour les modèles. Je recherche un poste de **Data Engineer** en CDI ou CDD, partout en France.

Réalisations clés : pipeline ETL Python — **388 articles** collectés via API CrossRef • base SQL structurée — **2 297 formulations** (43 variables) et **388 images** • qualité des données — **+86 %** de données exploitables après caption-matching • traçabilité complète avec identifiants sources (`_src`).

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire, IA multimodale & Data Engineering

Laboratoire L2MGC, CY Cergy Paris Université

2026 — présent

Cergy, France

- Pipeline ETL Python** : automatisation de la collecte d'articles scientifiques via API CrossRef (JSON, web scraping) et normalisation des champs.
- Structuration SQL** : base relationnelle de **2 297 formulations** (43 variables) et **388 images** MEB/BSE, avec contrôle d'intégrité et traçabilité (`_src`).
- Qualité des données** : détection d'anomalies, gestion des valeurs manquantes et doublons ; augmentation de **+86 %** des données exploitables par caption-matching.
- Feature engineering** : segmentation multi-Otsu sur images BSE et extraction de matrices GLCM pour enrichir le jeu de données.
- Modélisation et benchmark** : comparaison de **6 modèles** (XGBoost, réseaux de neurones, régressions) en validation croisée ; **XGBoost meilleur modèle avec $R^2 = 0,76$** et MAE < 10 MPa.
- Reproductibilité** : pipeline documenté et versionné (Git), présenté aux chercheurs.

Environnement : Python (pandas, scikit-learn, requests, BeautifulSoup), SQL, XGBoost, PyTorch, OpenCV, Git, LaTeX.

Stagiaire R&D, explicabilité de réseaux de neurones (XAI)

Laboratoire IRIT, Université de Toulouse

2024

Toulouse, France

- Préparation et transformation de données** : extraction, nettoyage et organisation de sorties de modèles (CNN/ResNet) pour analyse.
- Visualisation et restitution** : conception de dashboards interactifs (Python, Matplotlib) pour explorer prédictions et explications, adoptés par les équipes de recherche.
- Implémentation reproductible en Python (PyTorch, NumPy) avec documentation technique.

Environnement : Python, PyTorch, NumPy, Matplotlib, Jupyter.

PROJETS

Agent IA de candidature, application déployée en ligne

2026 — présent

Pipeline complet d'ingestion et d'analyse d'offres d'emploi et de CV : scoring de correspondance, intégration d'un **LLM** pour la rédaction de lettres de motivation et déploiement web.

Prévision de séries temporelles par Deep Learning

2025 — présent

Préparation et alimentation d'un pipeline de séries temporelles (dont financières) pour l'entraînement de modèles récurrents (**RNN, LSTM, GRU**) sous PyTorch.

Reconstruction d'images et analyse statistique sous incertitude

2025 — présent

Reconstruction d'images couleur (capteur de Bayer) évaluée par **PSNR / SSIM** ; étude de robustesse par simulations de **Monte-Carlo** et bootstrap.

FORMATION

Master Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

Université de Toulouse

2024 — 2026

Toulouse, France

- M2 MApI3 (2025 — 2026)** : Machine learning, réseaux de neurones profonds, big data, statistiques avancées, optimisation, traitement du signal et de l'image, recherche opérationnelle. *M2 validé (attestation de réussite ; diplôme officiel en décembre 2026).*
- M1 MApI3 (2024 — 2025)** : Statistiques inférentielles, modélisation stochastique, méthodes numériques (EDP), Monte-Carlo, plans d'expériences, analyse d'incertitude.

Licence Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

Université de Toulouse

2020 — 2023

Toulouse, France

- L3 MApI3 (2022 — 2023)** : Mathématiques appliquées à l'ingénierie, l'industrie et l'innovation.
- L1 — L2 CUPGE (2020 — 2022)** : Cycle Universitaire Préparatoire aux Grandes Écoles — analyse réelle et complexe, topologie, algèbre linéaire et calcul matriciel, probabilités et statistiques, programmation scientifique (Python, MATLAB).

COMPÉTENCES

Data Engineering : conception de bases SQL, pipelines ETL/ELT, structuration de données, qualité & fiabilité, web scraping (BeautifulSoup, Selenium, requests, API CrossRef), traçabilité et contrôle d'intégrité.

Langages et outils : Python (pandas, NumPy, SciPy, Matplotlib), SQL, MATLAB, OpenCV, Git/GitHub, Jupyter, LaTeX.

Machine Learning et IA : PyTorch, TensorFlow/Keras, scikit-learn, XGBoost, CNN, ResNet, RNN/LSTM/GRU, SVM, forêts aléatoires, clustering (k-means, DBSCAN), régularisation (ridge, lasso), optimisation d'hyperparamètres, validation croisée, XAI (Grad-CAM, t-SNE).

Statistiques et modélisation : inférence statistique, Monte-Carlo, bootstrap, quantification d'incertitude, plans d'expériences, méthodes numériques (EDP).

Signal et image : filtrage, segmentation, transformées (Fourier, ondelettes), reconstruction, métriques PSNR / SSIM.

LANGUES

Français : courant | Anglais : B2, documentation technique et rédaction scientifique.