

MOUSSA DIALLO

Data Engineer Junior | ML Engineer

Pipelines de données & Machine Learning & Mathématiques Appliquées

Toulouse / Île-de-France (mobile en France) | 06 65 78 47 63 | diallomoussa052001@gmail.com

LinkedIn : [Moussa Diallo](#) | GitHub : [dialloalassane052001-ui](#) | Portfolio : [Agent IA de candidature \(Streamlit Cloud\)](#)

PROFIL

Data Engineer junior formé par deux stages en laboratoire de recherche, avec une double compétence pipelines de données et machine learning : collecte automatisée (API, web scraping), structuration et feature engineering de jeux de données complexes (tabulaires + images), puis mise à disposition pour la modélisation. Pipeline développé en autonomie ayant traité 2 297 formulations et 483 images et augmenté de 86 % le volume de données exploitables. Maîtrise de SQL, Git, FastAPI, Streamlit et bases de Docker. Master 2 Mathématiques Appliquées, Université de Toulouse. Disponible immédiatement, mobile en France.

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire – IA multimodale pour la prédiction de propriétés de matériaux Avril 2026 – Juillet 2026

Laboratoire L2MGC, CY Cergy Paris Université

- Conçu et développé un pipeline de collecte automatisée (API CrossRef, web scraping) sur 388 articles scientifiques, puis structuré une base de 2 297 formulations (43 variables) et 483 images pour alimenter la modélisation en aval.
- Développé un pipeline de feature engineering (segmentation multi-Otsu, matrices GLCM, caption-matching pour l'association image-texte) qui a augmenté de 86 % le volume de données exploitables par les équipes de recherche.
- Mis en place et comparé 6 architectures de modélisation (XGBoost, Random Forest, MLP, ResNet18, fusion multimodale) sur les données produites : meilleur résultat $R^2 = 0,76$, $MAE < 10$ MPa, avec contrôle qualité par interprétabilité (t-SNE, Grad-CAM).

Environnement : Python (pandas, scikit-learn, OpenCV), PyTorch, XGBoost, SQL, Git

Stagiaire R&D – Explicabilité de réseaux de neurones (XAI) Mai 2025 – Août 2025

Laboratoire IRIT, Université de Toulouse

- Développé et versionné (Git) des modules Python/PyTorch/NumPy réutilisables pour générer des cartes Grad-CAM et calculer l'importance des filtres sur des CNN et ResNet.
- Conçu des dashboards interactifs (Python, Matplotlib) alimentés par ces modules, adoptés par les équipes de recherche pour exploiter les résultats sans recoder d'analyse.
- Documenté l'ensemble du pipeline (code, dépendances, structure des données) pour faciliter sa reprise et sa maintenance par d'autres chercheurs.

Environnement : Python, PyTorch, NumPy, Matplotlib, Jupyter, Git

COMPÉTENCES

Data Engineering & MLOps : SQL, pipelines ETL, web scraping (BeautifulSoup, Selenium), API REST/JSON, Git/GitHub, Linux, Docker (bases), FastAPI, Streamlit, Spark/PySpark, AWS (S3, EC2), GCP

Machine Learning & IA : PyTorch, TensorFlow/Keras, scikit-learn, XGBoost/LightGBM, CNN, ResNet, RNN/LSTM/GRU, Transformers, NLP (LLM), Computer Vision, XAI (Grad-CAM, t-SNE)

Analyse & statistiques : pandas, NumPy, SciPy, statistiques inférentielles, Monte-Carlo, détection d'anomalies, Matplotlib/Seaborn/Plotly

Calcul scientifique : optimisation, traitement du signal/image, MATLAB, OpenCV

PROJETS

- Agent IA de candidature** (Python, LLM/Gemini API) – Pipeline complet (ingestion offre/CV, scoring, génération de lettres) packagé en application Streamlit + CLI, avec traitement par lot, déployé sur Streamlit Cloud.
- Classification et explicabilité d'images** (PyTorch, projet d'équipe M2) – Pipeline de classification binaire (MNIST, Muffin vs. Chihuahua) par CNN/ResNet, avec module d'analyse Grad-CAM des décisions selon la complexité des données.
- Classification de paysages** (Deep Learning & Transfer Learning, PyTorch) – Pipeline d'entraînement sur 4 000 images / 7 classes ; comparaison from-scratch vs. data augmentation vs. transfer learning ; visualisation t-SNE.

FORMATION

Master 2 Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MAPI3) 2025 – 2026

Université de Toulouse Paul Sabatier · Attestation de réussite obtenue, diplôme officiel en décembre 2026

Master 1 MAPI3 2024 – 2025

Université de Toulouse Paul Sabatier

Licence Mathématiques Appliquées (MAPI3, dont CUPGE) 2021 – 2023

Université de Toulouse Paul Sabatier

LANGUES

Français : courant | Anglais : B2 (documentation technique, rédaction scientifique)