



# MOUSSA DIALLO

## DATA SCIENTIST JUNIOR — MACHINE LEARNING & DEEP LEARNING

Téléphone : 06 65 78 47 63 | Email : diallomoussa052001@gmail.com

Localisation : Toulouse, mobile partout en France | Disponibilité : immédiate (CDI / CDD)

GitHub : [github.com/dialloalassane052001-ui](https://github.com/dialloalassane052001-ui) | LinkedIn : [linkedin.com/in/moussa-diallo-b203473a2](https://linkedin.com/in/moussa-diallo-b203473a2)

### PROFIL

**Master 2 Mathématiques Appliquées (MApI3, Université de Toulouse) validé**, diplôme officiel délivré en décembre 2026. Data Scientist junior spécialisé en **Machine Learning**, **Deep Learning** et **IA multimodale**, avec une double compétence en **Data Engineering** (SQL, ETL, web scraping). Deux stages en laboratoire m'ont permis de couvrir toute la chaîne, de la donnée brute au modèle validé et déployé. Je recherche un poste de **Data Scientist** en CDI ou CDD, partout en France.

**Réalisations clés** :  $R^2 = 0,76$  en prédiction de propriétés mécaniques (XGBoost, +86 % vs baseline) • **2 297 formulations** et **388 images** structurées en base SQL • **6 modèles** ML/DL benchmarkés • outils XAI (Grad-CAM) pour CNN/ResNet.

### EXPÉRIENCE PROFESSIONNELLE

#### Data Scientist stagiaire, IA multimodale pour la prédiction de propriétés de matériaux

2026 — présent

Laboratoire L2MGC, CY Cergy Paris Université

Cergy, France

- Conception d'un modèle d'IA multimodale** combinant données tabulaires et images microscopiques (MEB/BSE) pour prédire la résistance mécanique du béton à partir de données scientifiques hétérogènes.
- Data Engineering** : automatisation de la collecte d'articles scientifiques (API CrossRef, JSON, web scraping) et structuration de **2 297 formulations** (43 variables) et **388 images** en base SQL, avec contrôle d'intégrité et traçabilité.
- Feature engineering** : segmentation multi-Otsu sur images BSE et extraction de matrices GLCM ; algorithme de caption-matching associant 141 images aux formulations (+86 % de données exploitables).
- Modélisation et benchmark** : comparaison de **6 modèles** (XGBoost, réseaux de neurones, régressions) en validation croisée ; **XGBoost meilleur modèle** avec  $R^2 = 0,76$  et MAE < 10 MPa (3× supérieur à la baseline).
- Interprétabilité** : analyse par t-SNE et Grad-CAM ; pipeline documenté et présenté aux chercheurs.

Environnement : Python (pandas, scikit-learn), XGBoost, PyTorch, OpenCV, SQL, Git, LaTeX.

#### Stagiaire R&D, explicabilité de réseaux de neurones (XAI)

2024

Laboratoire IRIT, Université de Toulouse

Toulouse, France

- Développement d'outils XAI** pour CNN et ResNet (cartes Grad-CAM, importance des filtres) afin d'interpréter les décisions de classification d'images.
- Visualisation et restitution** : conception de dashboards interactifs (Python, Matplotlib) pour explorer prédictions et explications, adoptés par les équipes de recherche.
- Implémentation reproductible en Python (PyTorch, NumPy) avec documentation technique.

Environnement : Python, PyTorch, NumPy, Matplotlib, Jupyter.

### PROJETS

#### Agent IA de candidature, application déployée en ligne

2026 — présent

Pipeline complet d'ingestion et d'analyse d'offres d'emploi et de CV : scoring de correspondance, intégration d'un LLM pour la rédaction de lettres de motivation et déploiement web.

#### Prévision de séries temporelles par Deep Learning

2025 — présent

Benchmark d'architectures récurrentes (RNN, LSTM, GRU) sous PyTorch pour la prédiction de séries temporelles (dont financières) et la génération de séquences.

#### Reconstruction d'images et analyse statistique sous incertitude

2025 — présent

Reconstruction d'images couleur (capteur de Bayer) évaluée par PSNR / SSIM ; étude de robustesse par simulations de Monte-Carlo et bootstrap.

### FORMATION

#### Master Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

2024 — 2026

Université de Toulouse

Toulouse, France

- M2 MApI3 (2025 — 2026)** : Machine learning, réseaux de neurones profonds, big data, statistiques avancées, optimisation, traitement du signal et de l'image, recherche opérationnelle. *M2 validé (attestation de réussite ; diplôme officiel en décembre 2026).*
- M1 MApI3 (2024 — 2025)** : Statistiques inférentielles, modélisation stochastique, méthodes numériques (EDP), Monte-Carlo, plans d'expériences, analyse d'incertitude.

#### Licence Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

2020 — 2023

Université de Toulouse

Toulouse, France

- L3 MApI3 (2022 — 2023)** : Mathématiques appliquées à l'ingénierie, l'industrie et l'innovation.
- L1 — L2 CUPGE (2020 — 2022)** : Cycle Universitaire Préparatoire aux Grandes Écoles — analyse réelle et complexe, topologie, algèbre linéaire et calcul matriciel, probabilités et statistiques, programmation scientifique (Python, MATLAB).

### COMPÉTENCES

**Machine Learning et IA** : PyTorch, TensorFlow/Keras, scikit-learn, XGBoost, CNN, ResNet, RNN/LSTM/GRU, SVM, forêts aléatoires, clustering (k-means, DBSCAN), régularisation (ridge, lasso), optimisation d'hyperparamètres, validation croisée, XAI (Grad-CAM, t-SNE).

**Langages et outils** : Python (pandas, NumPy, SciPy, Matplotlib), SQL, MATLAB, OpenCV, Git/GitHub, Jupyter, LaTeX.

**Data Engineering** : conception de bases SQL, pipelines ETL, web scraping (BeautifulSoup, Selenium, requests), nettoyage et structuration de données hétérogènes.

**Statistiques et modélisation** : inférence statistique, Monte-Carlo, bootstrap, quantification d'incertitude, plans d'expériences, méthodes numériques (EDP).

**Signal et image** : filtrage, segmentation, transformées (Fourier, ondelettes), reconstruction, métriques PSNR / SSIM.

### LANGUES

Français : courant (natif). | Anglais : B2, documentation technique et rédaction scientifique.