

Moussa DIALLO

Data Scientist / Machine Learning Engineer, Mathématiques Appliquées

Tél : 06 65 78 47 63 · Email : dialloussa052001@gmail.com · Toulouse / Île-de-France, mobile en France
https://github.com/dialloalassane052001-ui · https://www.linkedin.com/in/moussa-diallo-b203473a2/

PROFIL

Titulaire d'un Master 2 Mathématiques Appliquées (MApI3, Université de Toulouse), attestation de réussite obtenue, diplôme officiel en décembre 2026. Double compétence en modélisation mathématique et apprentissage statistique : deep learning, IA multimodale, séries temporelles, interprétabilité. Deux stages en laboratoire couvrant toute la chaîne, de la collecte de données à la modélisation prédictive.

Ce que je recherche : un poste de Data Scientist, Machine Learning Engineer ou AI Engineer en CDI ou CDD, disponible à partir d'octobre 2026, partout en France. Je souhaite mettre mes compétences en modélisation prédictive et en deep learning au service de projets à fort impact, en industrie ou en R&D.

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire — IA multimodale pour la prédiction de propriétés de matériaux

Laboratoire L2MGC, CY Cergy Paris Université · avril 2026 – juillet 2026

- Conception d'un modèle d'IA multimodale combinant données tabulaires et images microscopiques (MEB/BSE) pour prédire la résistance mécanique du béton.
- Data engineering** : collecte automatisée de 388 articles via API CrossRef (JSON, web scraping) ; structuration de 2 297 formulations (43 variables) et 483 images.
- Feature engineering** : segmentation multi-Otsu, matrices GLCM, caption-matching (+86 % de données exploitables).
- Benchmark de 6 modèles** (XGBoost, Random Forest, MLP, ResNet18, fusion multimodale) en validation croisée ; XGBoost meilleur : $R^2 = 0,76$, MAE < 10 MPa.
- Interprétabilité (XAI)** : analyse t-SNE et Grad-CAM ; restitution auprès des chercheurs.

Environnement : Python (pandas, scikit-learn, OpenCV), PyTorch, XGBoost, Random Forest, MLP, ResNet18, fusion multimodale, SQL, Git.

Stagiaire R&D — Explicabilité de réseaux de neurones (XAI)

Laboratoire IRIT, Université de Toulouse · mai 2025 – août 2025

- Développement d'outils XAI pour CNN et ResNet (cartes Grad-CAM, importance des filtres).
- Dashboards interactifs (Python, Matplotlib) adoptés par les équipes de recherche.
- Implémentation Python (PyTorch, NumPy) documentée et versionnée.

Environnement : Python, PyTorch, NumPy, Matplotlib, Jupyter, Git.

PROJETS

- Agent IA de candidature** : pipeline complet (analyse sémantique d'offres et de CV, scoring, intégration d'un LLM, déploiement web).
- Prévision de séries temporelles** : benchmark d'architectures récurrentes (RNN, LSTM, GRU) sous PyTorch.
- Demosaïcage d'images couleur** : inversion du filtre de Bayer par optimisation variationnelle (variation totale), avec étude de convergence.

FORMATION

Master 2 Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

Université de Toulouse, Paul Sabatier · septembre 2025 – août 2026 · Diplômé (attestation de réussite ; diplôme officiel décembre 2026)

- Mathématiques du machine learning, réseaux de neurones profonds, optimisation, calcul scientifique, traitement du signal et de l'image, statistiques avancées, recherche opérationnelle, plan d'expérience et analyse d'incertitude, Big Data.

Master 1 Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation (MApI3)

Université de Toulouse, Paul Sabatier · septembre 2024 – août 2025

- EDP et méthodes numériques, optimisation, probabilités, statistiques, simulation aléatoire, image, signal, algorithmique et calcul scientifique.

Licence Mathématiques Appliquées (MApI3)

Université de Toulouse, Paul Sabatier · septembre 2021 – mai 2023

- L3 MApI3 : Licence Mathématiques Appliquées à l'Ingénierie, l'Industrie et l'Innovation.
- L1–L2 CUPGE : Cycle universitaire préparatoire aux grandes écoles – Sciences pour l'Ingénieur (Maths, Physique, Informatique, Chimie).

COMPÉTENCES

Machine Learning & IA : apprentissage supervisé / non supervisé / multimodal, régression (linéaire, logistique, Ridge, Lasso), arbres de décision, Random Forest, Gradient Boosting (XGBoost, LightGBM), SVM, KNN, clustering (K-means), PCA, PyTorch, TensorFlow/Keras, scikit-learn, CNN, ResNet, RNN/LSTM/GRU, Transformers, autoencodeurs, transfer learning, NLP (embeddings, LLM), Computer Vision, séries temporelles, XAI (Grad-CAM, t-SNE), validation croisée, optimisation d'hyperparamètres.

Data Engineering : pipelines ETL, SQL (PostgreSQL, MySQL), structuration de données, qualité et traçabilité, web scraping (BeautifulSoup, Selenium, requests), API REST, JSON, Git/GitHub, Linux, Bash, Docker (bases), FastAPI, Streamlit, déploiement de modèles.

Data Analysis & Statistiques : analyse exploratoire, statistiques inférentielles, tests d'hypothèses, Monte-Carlo, bootstrap, quantification d'incertitude, détection d'anomalies, datavisualisation (Matplotlib, Seaborn, Plotly), pandas, NumPy, SciPy.

Calcul scientifique & signal : méthodes numériques, simulation, optimisation continue, traitement du signal et de l'image, segmentation multi-Otsu, matrices GLCM, Fourier, ondelettes, PSNR/SSIM, MATLAB, OpenCV.

Big Data & Cloud (notions) : Spark/PySpark, Hadoop, Hive, AWS (S3, EC2), GCP.

LANGUES

Français : courant · Anglais : B2 (documentation technique, rédaction scientifique).