

MOUSSA DIALLO

Data Scientist Junior | Machine Learning Engineer

Toulouse / Île-de-France (mobile en France) | 06 65 78 47 63 | diallomoussa052001@gmail.com
Linkedin : [Moussa Diallo](#) | Github : [github.com](#) | Portfolio : [Moussa Diallo](#)

PROFIL

Data Scientist junior diplômé d'un Master 2 Mathématiques Appliquées (Université de Toulouse III Paul Sabatier, 2026). Deux stages en laboratoire de recherche : collecte de données hétérogènes, feature engineering, modélisation Machine Learning / Deep Learning (XGBoost, PyTorch) et explicabilité (XAI). Recherche un poste de Data Scientist / Machine Learning Engineer junior en CDI ou CDD. Disponible immédiatement.

FORMATION

Master 2 Mathématiques Appliquées (MApI3)2025 – 2026

Université de Toulouse III Paul Sabatier · Attestation de réussite obtenue, diplôme officiel en décembre 2026

Master 1 Mathématiques Appliquées (MApI3)2024 – 2025

Université de Toulouse III Paul Sabatier

Licence Mathématiques Appliquées (CUPGE puis L3)2021 – 2024

Université de Toulouse III Paul Sabatier

EXPÉRIENCE PROFESSIONNELLE

Data Scientist stagiaire – IA multimodale & Deep Learning Avril 2026 – Juillet 2026

Laboratoire L2MGC, CY Cergy Paris Université

- **Modélisation multimodale** : modèle de Machine Learning prédisant la résistance mécanique du béton à partir de données tabulaires et d'images MEB/BSE ; 6 approches comparées (XGBoost, Random Forest, MLP, ResNet18, fusion) ; meilleur résultat : $R^2 = 0,76$ et MAE < 10 MPa (XGBoost).
- **Pipelines de données** : ingestion automatisée de 388 articles scientifiques (API CrossRef, BeautifulSoup, Selenium) ; jeu de données structuré de 2 297 formulations (43 variables) et 483 images, constitué avec Python (pandas) ; feature engineering (multi-Otsu, GLCM, caption-matching) : +86 % de données exploitables.
- **Interprétabilité (XAI)** : cartes Grad-CAM et analyses t-SNE pour fiabiliser les prédictions, restituées aux chercheurs.
- **Environnement** : Python, pandas, NumPy, scikit-learn, OpenCV, PyTorch, XGBoost, Git, Linux.

Stagiaire R&D – Explicabilité de réseaux de neurones (XAI) Mai 2025 – Août 2025

Laboratoire IRIT, Université de Toulouse

- **Outils XAI** : développement d'algorithmes d'explicabilité pour CNN / ResNet18 (importance des filtres, Grad-CAM) pour auditer les biais de décision des modèles.
- **Dashboards** : interfaces interactives (Python, Matplotlib) de suivi de la convergence et de l'interprétation des modèles, utilisées par les chercheurs.
- **Industrialisation** : modules réutilisables et documentés (PyTorch, NumPy) sous Git pour garantir la reproductibilité.
Environnement : Python, PyTorch, NumPy, Jupyter, Git.

COMPÉTENCES

Machine Learning & Deep Learning : PyTorch, scikit-learn, XGBoost, Random Forest, MLP, CNN, ResNet, Computer Vision, XAI (Grad-CAM, t-SNE), validation croisée

Données & programmation : Python, SQL (bases), pandas, NumPy, SciPy, OpenCV, pipelines ETL, web scraping (BeautifulSoup, Selenium), API REST / JSON

Outils : Git / GitHub, Linux, Jupyter, Streamlit, Matplotlib

PROJETS

- **Agent IA de candidature (projet personnel)** : analyse sémantique offre / CV et score de correspondance par LLM (API Gemini), génération de lettres de motivation ; application Streamlit + CLI déployée sur Streamlit Cloud.
- **Classification d'images & explicabilité (PyTorch, projet M2)** : classifieurs CNN / ResNet (MNIST, Muffin vs Chihuahua) avec étude Grad-CAM.
- **Classification de paysages (PyTorch)** : 4 000 images, 7 classes ; comparaison from-scratch, data augmentation et transfer learning ; projection t-SNE.

LANGUES

Français : courant | **Anglais** : B2 (documentation technique, veille, rédaction)